

PoC報告

変圧器オイル温度の短期予測PoC

ETTデータセットを用いた、LightGBMによる1ステップ先予測の検証

— 43.3%

ETTh2の1時間先予測誤差（MAE）
Naive（直前値）比

2026年10月

変動の大きい変圧器では、1ステップ先のOT予測誤差をNaive比で最大43%削減できた。保全判断への活用には、予測ホライズンの延長が次の検証課題

ETTh2 (1時間先)

−43.3%

MAE 0.516°C (Naive 0.910°C)

ETTh2 (15分先)

−21.7%

MAE 0.181°C (Naive 0.231°C)

ETTh1 (1時間先)

−1.3%

MAE 0.429°C (Naive 0.435°C)

ETTh1 (15分先)

+0.3%

MAE 0.213°C (Naive 0.212°C)

EDAからの示唆

学習期間とテスト期間でOTの水準が大きく異なる（分布シフト）。直前値との相関は0.99以上で、Naiveが強いベースラインになる

アプローチと結果

「直前値 + 変化量」をLightGBMで予測し、外挿の問題を回避。日周変動の大きい変圧器ほど改善が大きく、小さい変圧器ではNaiveと同等

運用への示唆と次の一手

予測との乖離による異常検知に活用できる見込み。保全計画に必要な数時間～数日先の予測は未検証で、次のPoCで検証する

1ステップ先のOT予測を、時系列順の学習・検証・テスト分割で評価した

項目	設定
予測対象	OT（変圧器のオイル温度）
予測ホライズン	1ステップ先（ETTh：1時間先、ETTm：15分先）
入力に使う情報	時刻 $t-1$ 以前のセンサー値のみ（下記の仮定）
データ分割	時系列順に 学習60% / 検証10% / テスト30%（シャッフルなし）
評価指標	MAE・RMSE（℃、元のスケール）
ベースライン	Naive：直前のOTをそのまま予測値とする
モデル	データセットごとに個別のLightGBM（検証データでearly stopping）

データ分割（4データ共通の期間）


学習	検証	テスト
----	----	-----

学習：2016/07/01 ～ 2017/09/09
検証：2017/09/09 ～ 2017/11/21
テスト：2017/11/21 ～ 2018/06/26

置いた仮定

- 課題文の「将来予測」に沿い、時刻 t の予測には $t-1$ 以前の値のみ利用できるとした
- 4データは別々の変圧器とみなし、モデルを個別に学習した
- テストデータは最終評価にのみ使用し、調整は検証データで行った

学習期間とテスト期間でOTの水準が大きく異なる。値を直接予測するモデルは、学習範囲外への外挿に弱い



17.3°C → 6.4°C


ETTh1の平均OT（学習期間 → テスト期間）

29.2°C → 21.5°C

ETTh2の平均OT（学習期間 → テスト期間）

- テスト期間は冬を含み、学習期間の大半より低温
- 決定木は学習データの範囲外の値を出力できない
- → 予測対象を「変化量」にする判断につながった



OTは直前値との相関が0.99以上で、Naiveが強いベースラインになる。一方、変化量（ ΔOT ）の自己相関は変圧器によって $-0.01 \sim 0.68$ と大きく異なる



読み取れること

- ΔOT の自己相関が高い＝変化に「勢い」があり、次の変化を予測できる余地がある
- ETTh2 (0.68) ・ ETTm2 (0.44) は改善の余地が大きいと予想
- ETTh1 (-0.01) ・ ETTm1 (0.08) の変化はほぼランダムで、Naiveを超えるのは難しいと予想
- → 結果 (p.9) はこの予想どおりになった

ETTh2は1日の中で約9℃変動し、時刻が変化の強い手がかりになる。負荷とOTの相関は $|r| \leq 0.5$ と弱い



- ETTh2は朝7時に最低、15時に最高（振れ幅 約9℃）。ETTh1は約2.4℃
- 負荷単体ではOTを説明しきれない → 時刻やOTのラグを組み合わせる

負荷の略称：HUFL/HULL = 高圧の有効/無効負荷、MUFL/MULL = 中圧、LUFL/LULL = 低圧

EDAを踏まえ、「直前値＋変化量」をLightGBMで予測する構成を採用した



なぜ変化量を予測するか

- 分布シフトがあっても、変化量は常に0付近に分布し外挿が起きにくい
- モデルが何も学べなくてもNaive相当になり、大きく負けない

なぜLightGBMか

- 1万～4万行の表形式データで高精度・高速に学習できる
- 時刻×負荷のような非線形な関係を扱え、重要度で解釈もできる

なぜデータごとに別モデルか

- 変圧器ごとに日周変動の大きさや負荷との相関が異なる (EDA③)
- ETThとETTmは時間間隔が異なり、ラグの意味が変わる

リークを防ぐため、すべての特徴量を時刻 t-1 以前の情報だけで構成した

グループ	特徴量	ETTh (1ステップ=1時間)	ETTm (1ステップ=15分)	狙い
カレンダー	hour, dayofweek	○	○ (+ minute)	日周期・週周期
OTのラグ	OT(t-k)	k = 1, 2, 3, 6, 12, 24, 48, 168	k = 1, 2, 3, 4, 8, 24, 48, 96, 192, 672	直近の値・1日前・1週間前
移動統計	平均・標準偏差	窓 24, 168	窓 96, 672	最近の水準・変動の大きさ
負荷	6種の負荷(t-1)	○	○	発熱の要因

実時間をそろえる

ラグは「ステップ数」で定義。ETThの24とETTmの96は、どちらも「1日前」になる

現在値の混入を防ぐ


移動統計はOTを1ステップずらしてから計算し、予測対象の値が入らないようにした

monthは不採用

学習期間が約14か月で各月をほぼ1回しか見えていないため。検証でも効果は誤差の範囲だった (p.12)

結果


テスト期間で、LightGBMはETTh2で43%、ETTm2で22%誤差を削減した。ETTh1・ETTm1はNaiveと同等だった



データ	MAE Naive	MAE LightGBM	MAE 改善率	RMSE Naive	RMSE LightGBM
ETTh1	0.435	0.429	−1.3%	0.628	0.617
ETTh2	0.910	0.516	−43.3%	1.278	0.734
ETTm1	0.212	0.213	+0.3%	0.313	0.311
ETTm2	0.231	0.181	−21.7%	0.354	0.254

- 改善の大きさは、EDA②の ΔOT の自己相関の順番と一致した
- ETTm1はMAEで0.3%劣るが、RMSEでは0.8%改善しており、大きな外れは減っている
- 検証データでも同じ傾向で、特定の期間に偶然合わせた結果ではない


ETTh2では、日中の上昇と夜間の下降という日周期の動きを追従できている




- テスト期間の最後の7日間（2018/6/20～6/26）。青が実測値、オレンジがLightGBMの予測値
- ピーク付近では予測が1ステップ遅れる傾向があり、急な変化の先読みは限定的

変化量の予測では時刻（hour）の寄与が39～52%と最も大きく、日周期のパターンが予測の中心になっている

ETTh1：重要度（gainの割合、上位8）



ETTh2：重要度（gainの割合、上位8）



- ・ 「この時間帯は上がる／下がる」という日周期が、変化量を予測する主な手がかりになっている
- ・ 負荷の寄与はETTh1のMUFL（7%）などに限られ、EDA③の相関の弱さと一致する。外気温など外部要因の追加が改善候補

最大の改善は「値の予測」から「変化量の予測」への切り替えによるもの。以降の調整は検証データで比較して決めた

#	試した設定	判断に使ったデータ	結果（MAE）	判断
1	OTの値を直接予測	テスト（初回評価）	4データ中3つでNaiveに負けた 例：ETTh1 0.649 vs Naive 0.435	不採用
2	変化量を予測（learning_rate 0.03）	検証	4データすべてでNaiveに勝った 例：ETTh2 0.476 vs Naive 0.836	採用
3	+ month 特徴量	検証	差は最大1%程度 例：ETTh2 0.476 → 0.471	不採用（効果が誤差の範囲で、過学習のリスクがある）
4	learning_rate 0.03 → 0.01	検証	ETTh2 0.476 → 0.471、ETTm2 0.167 → 0.163 ETTh1・ETTm1は同等	採用（最終）

リークの防止

時系列順に分割し、シャッフルなし。特徴量はすべて $t-1$ 以前

テストは最後に1回

#1のみ初回評価でテストを使った。以降の調整はすべて検証データで判断した

再現性

設定をconfig.pyに集約し、乱数シードを固定。3つのスクリプトで再現できる

短期予測の精度は「予測との乖離による異常検知」に活用できる見込み。保全計画に必要なリードタイムの確保は、まだ検証できていない

現時点で期待できる価値

- 予測値と実測値の乖離（残差）を監視し、負荷や時刻を考慮した異常検知ができる。固定の閾値監視より早い段階で異常に気づける可能性がある
- 例：通常の予測誤差（ETTh2のMAE 約0.5℃）を大きく超える乖離をアラート条件にする
- 日周変動が大きい変圧器（ETTh2型）ほど効果が高い

まだ言えないこと

- 予測は1時間先・15分先のみ。保全作業の計画に必要な数時間～数日先の予測精度は未検証
- 変動の小さい変圧器（ETTh1型）ではNaiveと同等で、予測モデルの追加価値は小さい
- 異常検知への有効性は、実際の異常事例のデータで確認する必要がある

次のPoCへの提案 「24時間先の予測」と「残差を使った異常検知」を、実際の異常事例のデータとあわせて検証する

現状は1ステップ先・1つの評価期間での検証にとどまる。予測ホライズンの延長と評価の頑健化を次のステップとする

現時点の限界

- 予測ホライズンが1ステップのみ
- 評価期間が1通り（冬～初夏の約7か月）で、乱数シードも1つ
- ETTh1・ETTM1ではNaiveとの差がほとんどない
- 外気温などの外部要因を使っていない（負荷では説明できない変動が残る）
- 値予測を不採用にする判断には、初回評価のテスト結果を使った

今後の改善方針（優先順）

- 多ホライズン予測（24時間先など）：保全判断のリードタイムを確保する
- ローリング評価：複数の期間・季節で精度が安定するか確認する
- 外気温データの追加（出典を明記）：負荷で説明できない変動を減らす
- 予測区間（分位点回帰）：アラート閾値の設計に使う
- 残差を使った異常検知のプロトタイプ作成

実装の構成と再現手順

ファイル	役割
src/config.py	パス・分割比率・ラグ・LightGBMのパラメータなど、設定を集約
src/preprocess.py	特徴量の作成と時系列順の分割
src/train.py	変化量の学習（early stopping）・モデル保存・検証スコアの表示
src/evaluate.py	テストデータでの評価（LightGBM vs Naive）・予測グラフの作成
src/eda.py / report_figures.py	EDAと報告用の図の作成

```
uv sync
uv run python src/preprocess.py
uv run python src/train.py
uv run python src/evaluate.py
uv run python src/eda.py
```

データ出典：ETDataset（zhouhaoyi/ETDataset, GitHub）